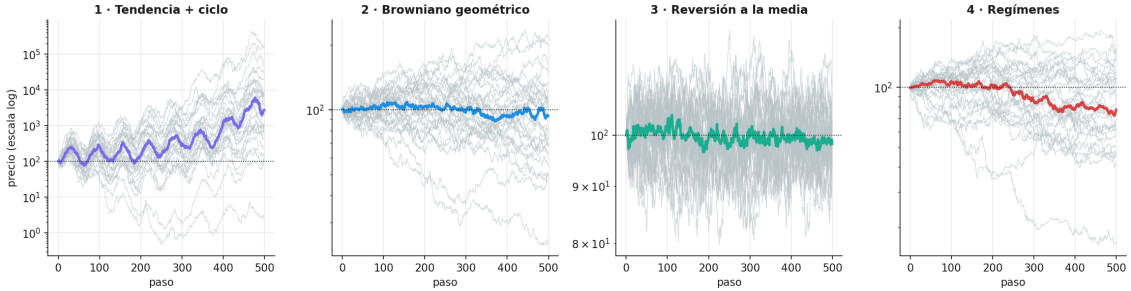
MÁSTER MIAX · APRENDIZAJE POR REFUERZO

Agentes de RL tabular para trading de un activo

Q-Learning y SARSA en cuatro mercados sintéticos y en el S&P 500

> *¿Puede un agente tabular aprender a invertir… y cuándo no?*

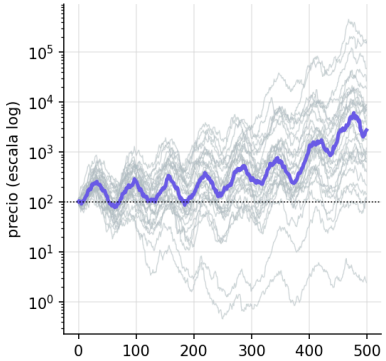


Óscar Romero Quincoces · Fernando Dapena Tauste · Daniel García López

Octubre 2026 · Código y resultados: github.com/Romequinco/rl-trading-agents

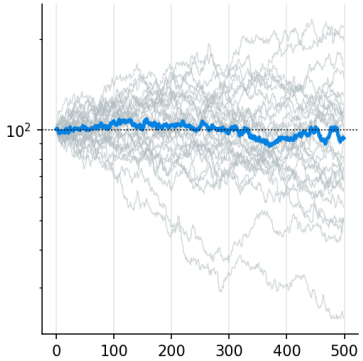
Cada mercado pide su estrategia, y el test se mira una sola vez

1 · Tendencia + ciclo



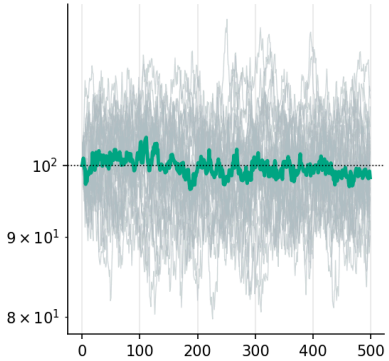
Seguir la tendencia

2 · Browniano



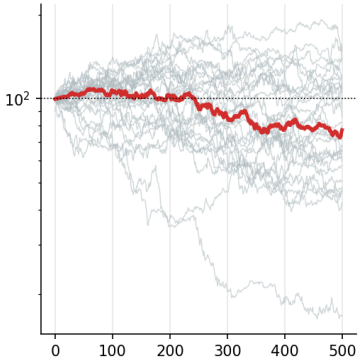
No operar: no hay señal

3 · Reversión a la media



Comprar caídas, vender subidas

4 · Regímenes



Dentro en alcista, fuera en bajista

Precio en escala log frente al paso (500 por serie): 30 series por mercado, una en color. Debajo, la estrategia que cabe esperar del generador.

ENTORNO

Vender, mantener o comprar; comisión del 0,1 %
Recompensa: retorno del paso con el activo dentro

→

ESTADO

10 bins de tendencia por cuantiles × posición = 20 estados

→

AGENTE

Q-Learning y SARSA tabulares
Ajuste por etapas: α, γ, ε y episodios

→

PROTOCOLO

Serie nueva en cada episodio
Validación: 100 series para elegir
Test: 200 series, una sola vez
Mediana de 5 semillas

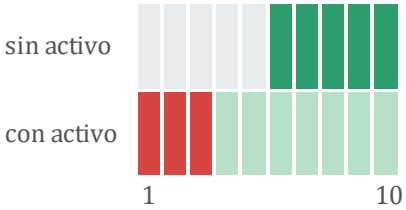
SARSA aprende la estrategia esperada en los cuatro mercados

$Q(S,A) \leftarrow Q(S,A) + \alpha\,[R + \gamma\,Q(S',A') - Q(S,A)]$ · α 0,0005 en 1 y 3 · γ 0 en el 1, 0,9 en reversión · 1 000 episodios en el 1

1 · Tendencia + ciclo

x472

buy & hold x33,6
aleatorio x4,3

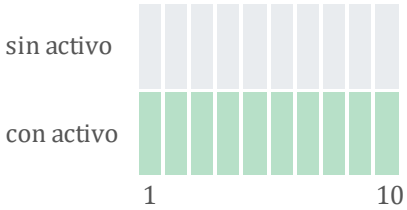


sigue la tendencia

2 · Browniano

0 %

buy & hold −3,5 %
aleatorio −19,4 %

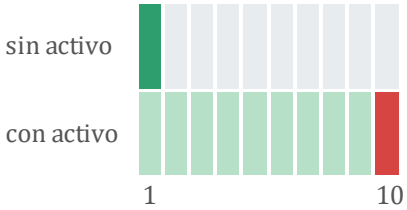


no opera

3 · Reversión a la media

+27,0 %

buy & hold −0,3 %
aleatorio −17,2 %

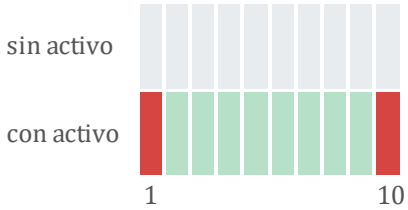


compra en bin 1, vende en 10

4 · Regímenes

0 %

buy & hold −12,5 %
aleatorio −22,0 %

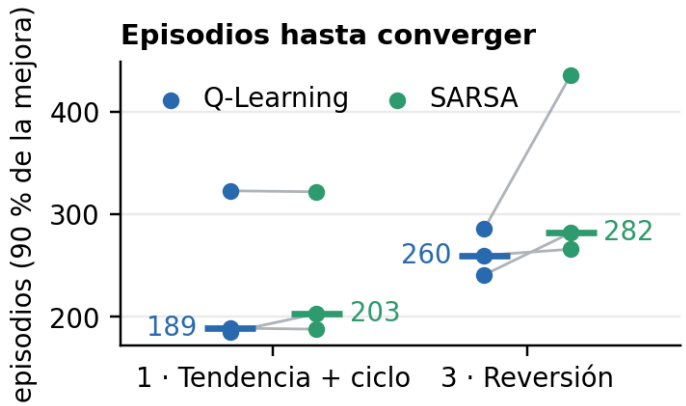


no opera

entrar salir dentro fuera · bin de tendencia: 1, caída más fuerte; 10, subida más fuerte
Retorno: mediana en las 200 series de test (5 semillas). Política: la acción que elige la mayoría de las semillas.

Misma política final; Q-Learning solo converge antes en reversión

$Q(S,A) \leftarrow Q(S,A) + \alpha\,[R + \gamma\ \text{máx}_a\ Q(S',a) - Q(S,A)]$ · α 0,001 · γ 0 en el 1, 0,5 en reversión · ε 0,98 / 0,05 en el 1



Duelo con la misma configuración (α 0,001, γ 0,9, 1 000 episodios) y las mismas 3 semillas. Converge: la media móvil de 50 episodios alcanza el 90 % de su mejora. Reversión: Q-Learning gana en las 3 semillas; mercado 1: en 1 de 3, empate.

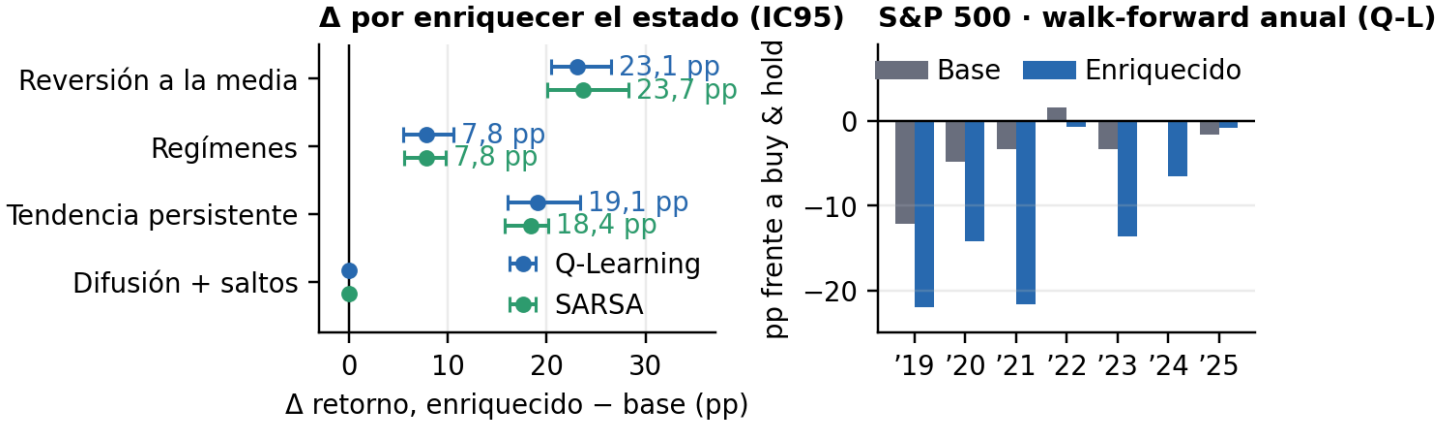
Test (mediana)	Aleatorio	B&H	Q-L	SARSA	Converg. (ep.)
1 · Tendencia	x4,3	x33,6	**x502**	**x472**	189 / 203
2 · Browniano	−19,4 %	−3,5 %	**0 %**	**0 %**	—
3 · Reversión	−17,2 %	−0,3 %	**+27,0 %**	**+27,0 %**	260 / 282
4 · Regímenes	−22,0 %	−12,5 %	**0 %**	**0 %**	—

Test: 200 series, mediana de 5 semillas, hiperparámetros propios de cada algoritmo. Convergencia: episodios en el duelo, Q-L / SARSA. En 2 y 4 no operar es lo correcto con este estado: en regímenes, la mejor de 70 reglas fijas da −8,6 % en validación.

Con 20 estados y ε final de 0,01 a 0,05, $Q(S',A') \approx \text{máx}\ Q(S',a)$: las 10 semillas del mercado 1 caen en tres políticas, y x502 frente a x472 refleja cuántas caen en cada una.

Lo que decide es la información del estado, no el algoritmo

Añadir MA30 y volatilidad (180 celdas) mejora donde el precio tiene memoria, con IC95 por encima de cero.



+23,1 pp
reversión a la media, mediana emparejada; casi todo lo aporta la MA30

+8,5 %
regímenes con solo la volatilidad (estado base: 0 %)

+45,9 % **frente a +44,2 %**
S&P 500, test 2024–2025: el estado base solo iguala a buy & hold y el enriquecido baja a +28,3 %

Robustez (anexo C): los placebos no dan ventajas falsas; ×4 episodios, Expected SARSA, Double Q o recompensa log apenas cambian nada. La comisión sí pesa.

CONCLUSIONES

Los dos algoritmos aprenden lo esperado; el límite está en el estado

MENSAJES CLAVE

- En los cuatro mercados los dos agentes superan a buy & hold y al aleatorio.
- Q-Learning y SARSA aprenden **la misma estrategia**, la que corresponde a cada generador.
- Q-Learning converge antes en reversión (3 de 3 semillas); en el mercado 1 empatan.
- El techo lo pone el estado; en el S&P 500 **no hay ventaja** sobre buy & hold.

LIMITACIONES Y TRABAJO FUTURO

- Estado de 20 celdas no markoviano: pasar a aproximación de funciones.
- La recompensa suma retornos y el balance se compone; un único recorrido real, sin dividendos ni *spread*.
- Generalización: entrenar en un mercado y evaluar en los otros (matriz 4 × 4).

Preguntas

Anexos

Detalle de los resultados que la exposición resume.

A	Ajuste de hiperparámetros: barridos de α, γ, ε y episodios, y valores elegidos
B	Políticas aprendidas por Q-Learning y SARSA, y un episodio de test
C	Robustez del estado enriquecido: indicadores, presupuesto, placebos, comisión, algoritmo y recompensa
D	S&P 500: cortes temporales, test 2024–2025, *walk-forward* anual y límites

Q-Learning y SARSA acaban con hiperparámetros casi iguales

Orden α → γ → ε → episodios; cada etapa parte de lo ya fijado. Punto de partida: α = 0,001, γ = 0,9, ε 0,99 / 0,01, 500 episodios.

	α						**γ**				**ε (decaimiento / mínimo)**						**episodios**			
	0,0005	0,001	0,003	0,01	0,03	0,1	0	0,5	0,9	0,99	0,98 0,01	0,98 0,05	0,99 0,01	0,99 0,05	0,995 0,01	0,995 0,05	250	500	1 000	2 000
Q-L · M1	x527	**x527**	x518	x527	x296	x14	**x596**	x527	x527	x527	x718	**x817**	x596	x668	x596	x596	x718	**x817**	x817	x817
SARSA · M1	**x527**	x504	x504	x527	x489	x19	**x668**	x527	x527	x527	x668	x596	**x668**	x596	x668	x668	x596	x668	**x817**	x743
Q-L · M3	+22,2	**+22,2**	+22,2	+20,1	0	0	0	**+34,0**	+22,2	+22,2	+34,0	+34,0	**+34,0**	+34,0	+27,1	+27,1	+34,0	**+34,0**	+30,6	+30,6
SARSA · M3	**+34,0**	+22,6	+23,5	+17,8	0	0	0	+34,0	**+34,0**	+34,0	+34,0	+22,2	**+34,0**	+22,1	+20,6	+20,6	+23,8	**+34,0**	+34,0	+34,0

Retorno en validación: mediana entre 3 semillas de la mediana en 100 series de validación. M1 (tendencia con ciclo) en múltiplo del capital; M3 (reversión a la media) en %. En azul, el valor que queda fijado. En los mercados 2 y 4 casi todas las celdas dan 0 % (no opera) y se mantiene el punto de partida.

Configuración final	α	γ	ε	Episodios	Test
Q-Learning · M1	0,001	0	0,98 / 0,05	500	x502
SARSA · M1	0,0005	0	0,99 / 0,01	1 000	x472
Q-Learning · M3	0,001	0,5	0,99 / 0,01	500	+27,0 %
SARSA · M3	0,0005	0,9	0,99 / 0,01	500	+27,0 %
Ambos · M2 y M4	0,001	0,9	0,99 / 0,01	500	0 %

Test: mediana de 5 semillas en 200 series (results/04_algoritmos.csv).

Regla de parsimonia. Un valor solo sustituye al vigente si gana en la mayoría de las semillas, comparando semilla a semilla, y tiene mejor mediana.

Por eso Q-Learning conserva α = 0,001 en M1 pese al empate con 0,0005 y 0,01, y 500 episodios pese al empate con 1 000 y 2 000. Sin la regla, el browniano habría elegido α = 0,01 por un +3,4 % debido a una sola operación.

α ≥ 0,03 hunde los resultados: x14 y x19 con α = 0,1 en M1.

Q-Learning y SARSA aprenden casi la misma tabla de decisiones

Acción *greedy* por bin de tendencia y posición que elige la mayoría de las 5 semillas; acuerdo indicado si no es del 100 %.

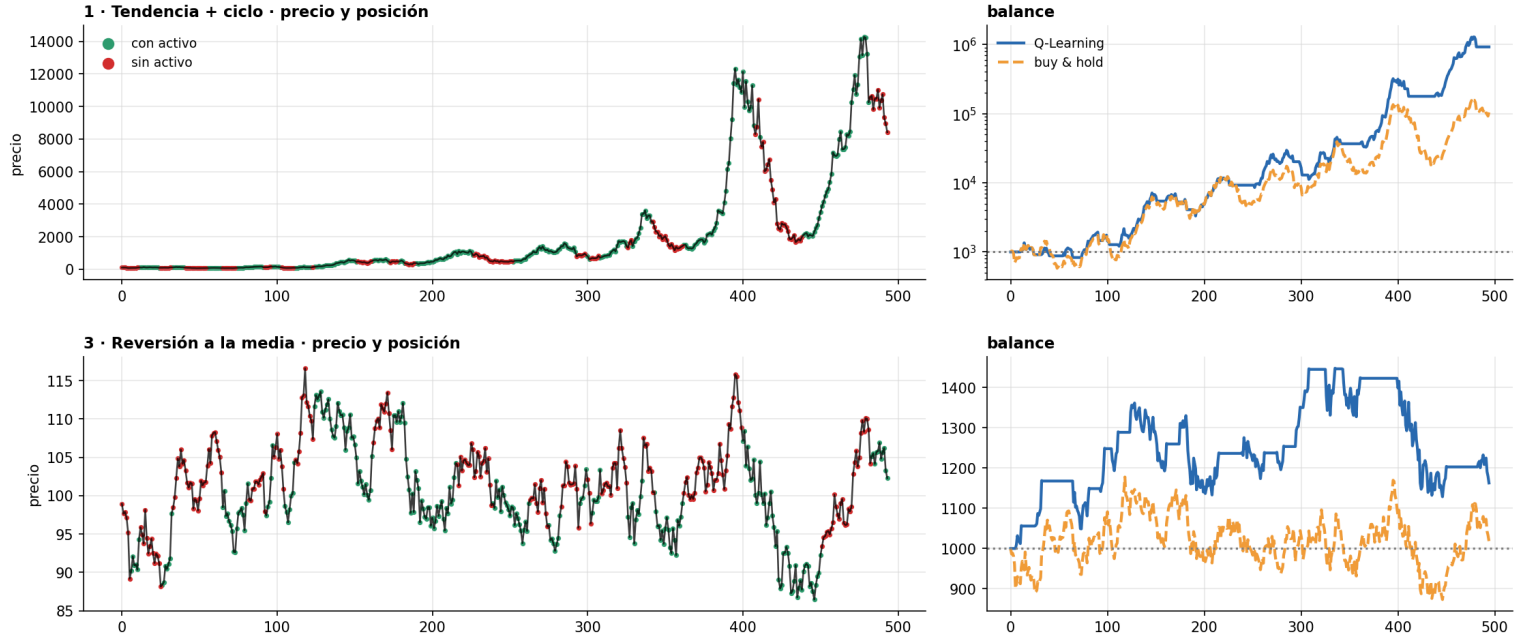
		1 ↓↓	2	3	4	5	6	7	8	9	10 ↑↑
1 · Tendencia con ciclo											
Q-Learning	sin activo	fuera	fuera	fuera	fuera	fuera	fuera 80 %	entrar	entrar	entrar	entrar
	con activo	salir	salir	salir 60 %	dentro	dentro	dentro	dentro	dentro	dentro	dentro
SARSA	sin activo	fuera	fuera	fuera	fuera	fuera	entrar 60 %	entrar	entrar	entrar	entrar
	con activo	salir	salir	salir 60 %	dentro	dentro	dentro	dentro	dentro	dentro	dentro
3 · Reversión a la media											
Q-Learning	sin activo	entrar	fuera	fuera	fuera	fuera	fuera	fuera	fuera	fuera	fuera
	con activo	dentro	dentro	dentro	dentro	dentro	dentro	dentro	dentro	dentro 80 %	salir
SARSA	sin activo	entrar	fuera 80 %	fuera 80 %	fuera	fuera	fuera	fuera	fuera	fuera	fuera
	con activo	dentro	dentro	dentro	dentro	dentro	dentro	dentro	dentro	dentro	salir

En los mercados 2 (browniano) y 4 (regímenes) los dos algoritmos eligen «fuera» sin activo en los 10 bins (100 % de las semillas): no entran nunca, así que la fila con activo no llega a usarse. Fuente: results/figures/01_politica_final.png y 02_politica_final.png.

> La única diferencia sistemática está en M1: SARSA ya entra en el bin 6 (3 de 5 semillas). En M3 los dos compran solo tras la caída más fuerte y venden tras la subida más fuerte.

El agente sigue la tendencia en M1 y opera los extremos en M3

Q-Learning final, semilla 0, una serie de test. Verde: con activo; rojo: sin activo. Derecha: balance frente a buy & hold (capital inicial 1 000). **M1:** dentro en los tramos alcistas, fuera en las caídas tras los picos (escala log). **M3:** entra tras caídas bruscas y sale tras subidas; el balance avanza a saltos y en esta serie cede parte en la caída final.



Recorte de results/figures/01_episodios_test.png (filas de los mercados 1 y 3). En M2 y M4 no entra y el balance queda plano en 1 000.

Ni los episodios ni el algoritmo mueven el resultado; la comisión sí

Retorno mediano en test (%)	Reversión	Regímenes	Tend. persistente	S&P 500
Estado base (20 celdas)	+18,1	0,0	+104,5	+45,9
Base + MA30	**+44,0**	0,0	**+120,6**	+37,2
Base + volatilidad	+25,5	**+8,5**	+109,0	+41,8
Enriquecido (ambos): referencia	**+42,8**	**+7,8**	**+123,8**	**+28,3**
×4 episodios (3 200)	+42,8	+8,2	+126,0	+28,7
Rango de 4 algoritmos TD	42,3 a 43,9	6,5 a 7,8	123,8 a 128,7	28,3 a 32,5
Recompensa log(balance)	+42,8	+8,1	+126,5	+28,7
Comisión 0 %	+45,8 (61)	+9,6 (44)	+128,0 (30)	
Comisión 0,25 %	+38,3 (16)	0,0 (2)	+123,6 (8)	
Comisión 0,5 %	+23,0 (6)	0,0 (0)	+79,6 (4)	
Buy & hold	−0,3	−12,5	+22,8	+44,2

Q-Learning, 800 episodios, configuración fija (α 0,001, γ 0,9, ε 0,99 / 0,01), mediana de 5 semillas en 200 historias de test (S&P 500: una trayectoria 2024–2025). Un factor cada vez respecto a la referencia; la comisión de referencia es 0,1 %. Entre paréntesis, operaciones por historia. Algoritmos: Q-Learning, SARSA, Expected SARSA y Double Q-Learning. Fuente: results/03_anexo.csv y 03_anexo_conclusiones.md.

Un indicador por mercado. MA30 en reversión y tendencia, volatilidad en regímenes: el que predice el mecanismo del generador.

No falta entrenamiento. Con ×4 episodios el estado de 180 celdas apenas se mueve.

Placebos. Browniano: 0,0 % con los dos estados. S&P 500 con retornos barajados: base +44,0 % y enriquecido +11,1 %, frente a +44,2 % de buy & hold. Sin señal, el agente no opera o compra y mantiene.

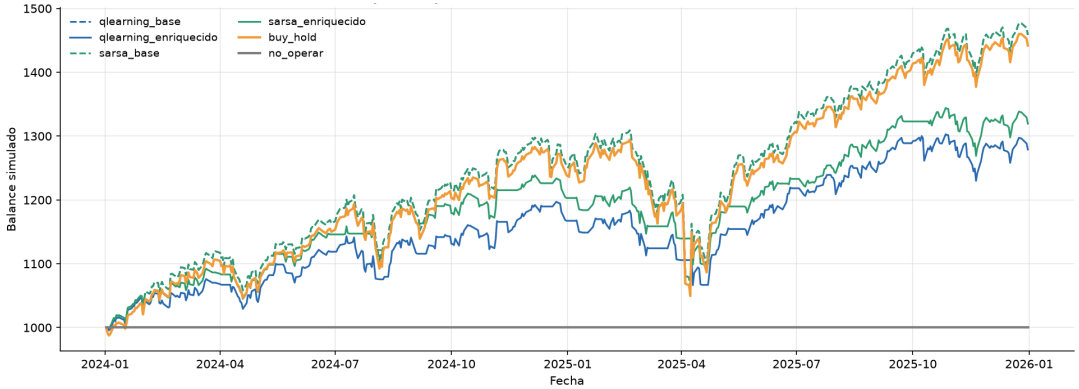
La comisión sí pesa. Reversión aguanta un 0,5 %; en regímenes la ganancia desaparece ya con un 0,25 %.

Recompensa log en M1: de x412 a x431.

Sin corrección por comparaciones múltiples.

En el S&P 500 ningún estado bate de forma consistente a buy & hold

Cierres diarios de FRED, 2017–2025 (2 262). Cortes fijados antes de entrenar: train 2017–2021 (1 259), validación 2022–2023 (501), test 2024–2025 (502). Bins y ventanas de 252 cierres solo con train.



Balance en test 2024–2025 con la Q congelada (semilla 0); recorte de 03_real_balance.png. La serie con sus cortes está en 03_serie_real_splits.png.

Límites: índice de precios sin dividendos, sin *spread* ni deslizamiento; una sola trayectoria de test, así que 5 semillas no son 5 historias independientes.

Test 2024–2025	Retorno	Caída máx.	Ops.
Buy & hold	+44,2 %	18,9 %	1
Q-L / SARSA base	+45,9 %	18,9 %	1
Q-L enriquecido	+28,3 %	11,4 %	79
SARSA enriquecido	+29,9 %	12,8 %	77

Walk-forward (Q-L)	B&H	Base	Enriq.
2019	+28,6	+16,5	+6,6
2020	+15,2	+10,4	+1,0
2021	+28,7	+25,3	+7,0
2022	−20,0	−18,4	−20,7
2023	+24,6	+21,3	+11,0
2024	+23,9	+23,9	+17,4
2025	+16,5	+14,9	+15,8

Retorno del año (%); se entrena solo con años anteriores. Mediana de 5 semillas (03_extras.csv, 03_anexo.csv).